

書籤:

- 執行說明
- 作 法
- 結 果
- 討 論

● 執行說明:

在 python 環境中執行 (此作業是在 anaconda3 上完成)

● 作法:

運算的部分都寫成 function，再將不同 data 代進去

所有的 Function:

```
regression(x_nd, y_1d)
trainingError(x, y, degree)
leaveOneOut(x, y, degree)
fiveFold(x, y, degree)
testingError(x, y, w, degree)

regularization(x_nd, y_1d, Lambda, dim)
trainingError_14d_regularization(x, y, Lambda)
leaveOneOut_14d_regularization(x, y, Lambda)
fiveFold_14d_regularization(x, y, Lambda)
testingError_14d_regularization(x, y, w, Lambda)

singlePlot(point_x, point_y, range_x, w, lim_x, lim_y)
integrationMap(point_x, point_y, range_x, w_1d, w_5d, w_10d, w_14d, lim_x, lim_y)
integrationMap_14d(point_x, point_y, range_x, Lambda1, Lambda2, Lambda3, Lambda4, lim_x, lim_y):
```

有 5 個 有關 regression 的 function, 5 個有關 regularization 的 function, 3 個畫圖的 function，接下來一一的介紹各個 function。

1. `regression(x_nd, y_1d)`

```
# get the function weight  $W = (X^T X)^{-1} X^T y$ 
def regression(x_nd, y_1d):
    return np.dot(np.dot(np.linalg.inv(np.dot(x_nd.T, x_nd)), x_nd.T), y_1d)
```

x_nd: training 的 x 化成的矩陣 (如, 5 維時 $x_nd = [x^5, x^4, x^3, x^2, x^1, 1]$)

y_1d: training 的 y

return regression 後的 Weight

.....
計算 regression 公式的 function，利用這 function 可以得到線性回歸後的權重。

2. `trainingError(x, y, degree)`

```
# testing error
def trainingError(x, y, degree):
    error = 0
    dim = degree+1
    num = y.size # data number
    x_nd = np.zeros((num, dim))
    for i in range(num):
        for j in range(dim):
            x_nd[i][j] = pow(x[i], j)
    global weight
    weight = regression(x_nd, y)

    #  $E_{in}(w) = 1/N * |Xw-y|^2$ 
    for i in range(num):
        error += math.pow((np.dot(x_nd[i].T, weight) - y[i]), 2)
    error /= num
    return error
```

X: training data 的 x

Y: training data 的 y

Degree: 要找的模型空間是多少維度

Return training error E_{in}

.....
計算 training error 的 function，將我們的 training data 和要求的維度代進去後，
他會回傳 training error。

這個 function 一進去會先把我們給他的 X 陣列根據我們的維度轉成矩陣

例如, `degree=5`, 我們會先把 X 轉成 $[x^5, x^4, x^3, x^2, x^1, 1]$ 。

之後將這個矩陣和我們給的 y 丟進 regression function, 得到 weight

```
weight = regression(x_nd, y)
```

最後再利用這個 weight 得到我們的模型，再利用這個模型將 x 值重新代進去算 y 值，之後將 y 值扣去實際的 y 值找他的誤差，並加總取平均，這就是 function return 的值。

3. `leaveOneOut(x, y, degree)`

```
# Leave one out
def leaveOneOut(x, y, degree):
    error = 0
    dim = degree+1
    num = y.size
    x_nd = np.zeros((num-1, dim))
    train_y = np.zeros(num-1)

    for i in range(num):
        k = 0
        for j in range(num):
            if i == j:
                test_x = x[j]
                test_y = y[j]
                continue
            else:
                for l in range(dim):
                    x_nd[k][l] = pow(x[j], l)
                train_y[k] = y[j]
                k=k+1
        #end of for loop
        w = regression(x_nd, train_y)
        y_prediction = 0
        for k in range(dim):
            y_prediction += w[k] * pow(test_x, k)
        error += math.pow((y_prediction - test_y), 2)
        #end of for loop
    error /= num
    return error
```

x: training data x

y: training data y

degree: 維度

return Leave-One-Out 的 E_{in}

.....
cross-validation errors 的 function 之一，這個 function 會先將我們給的 x 和 y 先抽出一組出來當作 testing data，再將剩下的 data 做 regression 後產出模型，再利用剛抽出來的 testing data 找他的誤差。

有幾組 data 就會做幾次，之後再取平均，就是 function 要 return 的值。

例如，有 15 組 x, y 傳 function，會重複上面動作 15 次(每一組都當過一次 testing data)，再將其誤差加總取平均。

4. `fiveFold(x, y, degree)`

```
# five-fold
def fiveFold(x, y, degree):
    error = 0
    dim = degree + 1
    num = y.size
    groupNum = 5
    testNum = int(num / groupNum)
    trainNum = num - testNum
    test_x = np.zeros(testNum)
    test_y = np.zeros(testNum)
    x_nd = np.zeros((trainNum, dim))
    train_y = np.zeros(trainNum)
    # split in 5 group
    for i in range(groupNum):
        k = 0
        l = 0
        for j in range(num):
            if j % groupNum == i:
                test_x[k] = x[j]
                test_y[k] = y[j]
                k = k + 1
            else:
                for m in range(dim):
                    x_nd[l][m] = pow(x[j], m)
                train_y[l] = y[j]
                l = l + 1
        #end of for loop
    w = regression(x_nd, train_y)
    for k in range(testNum):
        y_prediction = 0
        for l in range(dim):
            y_prediction += w[l] * pow(test_x[k], l)
        error += math.pow((y_prediction - test_y[k]), 2)
    #end of for loop
    error /= num
    return error
```

x: training data x

y: training data y

degree: 維度

return Five-fold 的 E_{in}

.....

這個 function 和上一個 function 一樣是做 cross-validation errors 的 function。

首先會先分成 5 組，其中一組拿來做 testing data，剩下四組 regression 後用先前抽出的 testing data 算他誤差，做五次後取平均(每組都做過一次 testing data)。

因為是分五組，所以每次算誤差加總後是除以 $M/5$ 次(假設 M 我們給 function 的資料數)，而總共 5 次所以會再除以 5，所以這個 function 是直接在最外面除以總

資料數。

```
error /= num
```

PS. 分組方式是 x, y 的 index 與 5 取餘數，相同的為一組，

假設有 15 筆 data => group1 = {(x[0], y[0]), (x[5], y[5]), (x[10], y[10])},

group2 = {(x[1], y[1]), (x[6], y[6]), (x[11], y[11])}.... 以此類推

5. `testingError(x, y, w, degree)`

```
def testingError(x, y, w, degree):
    num = y.size
    dim = degree + 1
    error = 0
    for i in range(num):
        y_prediction = 0
        for j in range(dim):
            y_prediction += w[j]*pow(x[i], j)
        error += math.pow((y_prediction - y[i]), 2)
    error /= num
    return error
```

x: testing data x

y: testing data y

w: training error 那個 function 算出來的 weight

degree: 維度

return testing error 的 E_{in}

.....
這個 function 不會做 regression, 他直接拿我們給的 weight 和我們給的 testing data 來算 E_{in} 。

6. `regularization(x_nd, y_1d, Lambda, dim)`

```
# get the function weight  $W = (X^T X + \lambda I)^{-1} X^T y$ 
def regularization(x_nd, y_1d, Lambda, dim):
    return np.dot(np.dot(np.linalg.inv((np.dot(x_nd.T, x_nd) + Lambda*np.eye(dim))), x_nd.T), y_1d)
```

x_nd: training 的 x 化成的矩陣 (如, 5 維時 $x_nd = [x^5, x^4, x^3, x^2, x^1, 1]$)

y_1d: training 的 y

Lambda: 我們 Regularization 的 λ

Dim: x 矩陣的大小($degree+1$) => 算 I 時使用

return regularization 後的 Weight

.....

$$w = (X^T X + \lambda I)^{-1} X^T y$$

7. `trainingError_14d_regularization(x, y, Lambda)`

```
def trainingError_14d_regularization(x, y, Lambda):
    error = 0
    dim = 15
    num = y.size # data number
    x_nd = np.zeros((num, dim))
    for i in range(num):
        for j in range(dim):
            x_nd[i][j] = pow(x[i], j)
    global weight
    weight = regularization(x_nd, y, Lambda, dim)
    # error
    for i in range(num):
        error += math.pow((np.dot(x_nd[i].T, weight) - y[i]), 2) + Lambda * np.dot(weight.T, weight)

    error /= num
    return error
```

x: training data x

y: training data y

Lambda: 我們 Regularization 的 λ

return training error 的 E_{in}

.....
這個 function 做的動作與前面介紹的 `trainingError` function 差不多，不同在於這邊已經直接訂為 14 維，且是使用 `regularization` 的方式來求 `weight` 及算誤差。

E_{in} :

$$J_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m (y_i - f(\mathbf{x}_i; \mathbf{w}))^2 + \lambda \|\mathbf{w}\|^2$$

Weight:

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

8. `leaveOneOut_14d_regularization(x, y, Lambda)`

```
def leaveOneOut_14d_regularization(x, y, Lambda):
    error = 0
    dim = 15
    num = y.size
    x_nd = np.zeros((num-1, dim))
    train_y = np.zeros(num-1)

    for i in range(num):
        k = 0
        for j in range(num):
            if i == j:
                test_x = x[j]
                test_y = y[j]
                continue
            else:
                for l in range(dim):
                    x_nd[k][l] = pow(x[j], l)
                train_y[k] = y[j]
                k=k+1
        #end of for loop
        w = regularization(x_nd, train_y, Lambda, dim)
        y_prediction = 0
        for k in range(dim):
            y_prediction += w[k] * pow(test_x, k)
        error += (math.pow((y_prediction - test_y), 2) + Lambda * np.dot(w.T, w))
        #end of for loop
    error /= num
    return error
```

x: training data x

y: training data y

Lambda: 我們 Regularization 的 λ

return leave-one-out 的 E_{in}

.....

與前面的 function 狀況相同，所以只貼 function 就不介紹了。詳細步驟與 LeaveOneOut 的部分差不多。不同的只在於是用 regularization 算 weight 和 E_{in}

9. `fiveFold_14d_regularization(x, y, Lambda)`

```
def fiveFold_14d_regularization(x, y, Lambda):
    error = 0
    dim = 15
    num = y.size
    groupNum = 5
    testNum = int(num / groupNum)
    trainNum = num - testNum
    test_x = np.zeros(testNum)
    test_y = np.zeros(testNum)
    x_nd = np.zeros((trainNum, dim))
    train_y = np.zeros(trainNum)
    # split in 5 group
    for i in range(groupNum):
        k = 0
        l = 0
        for j in range(num):
            if j % groupNum == i:
                test_x[k] = x[j]
                test_y[k] = y[j]
                k = k + 1
            else:
                for m in range(dim):
                    x_nd[l][m] = pow(x[j], m)
                    train_y[l] = y[j]
                    l = l + 1
        #end of for loop
        w = regularization(x_nd, train_y, Lambda, dim)
        # error
        for k in range(testNum):
            y_prediction = 0
            for l in range(dim):
                y_prediction += w[l] * pow(test_x[k], l)
            error += (math.pow((y_prediction - test_y[k]), 2) + Lambda * np.dot(w.T, w))
        #end of for loop
    error /= num
    return error
```

x: training data x

y: training data y

Lambda: 我們 Regularization 的 λ

return five-fold 的 E_{in}

.....

與前面的 function 狀況相同，所以只貼 function 就不介紹了。詳細步驟與 Fivefold 的部分差不多，分為五組且一樣利用 index 取 5 的餘數相同的一組來分組。不同的只在於是用 regularization 算 weight 和 E_{in}

```

10. testingError_14d_regularization(x, y, w, Lambda)

# testing error (Just only input test data)
def testingError_14d_regularization(x, y, w, Lambda):
    num = y.size
    dim = 15
    error = 0
    # w_norm = 0
    # for i in range(w.size):
    #     w_norm += abs(w[i])
    for i in range(num):
        y_prediction = 0
        for j in range(dim):
            y_prediction += w[j]*pow(x[i], j)
        error += (math.pow((y_prediction - y[i]), 2) + Lambda * np.dot(w.T, w))
    error /= num
    return error

```

x: testing data x

y: testing data y

w: training error 那個 function 算出來的 weight

Lambda: Regularization 的 λ

return testing error 的 E_{in}

.....

這個 function 不會最 regularization，他直接拿我們給的 weight 和我們給的 testing data 來算 E_{in} 。

```

11. singlePlot(point_x, point_y, range_x, w, lim_x, lim_y)

```

```

def singlePlot(point_x, point_y, range_x, w, lim_x, lim_y):
    dim = w.size
    plt.xlim(lim_x)
    plt.ylim(lim_y)
    plt.title("single plot (degree %d)" %(dim-1))
    plt.scatter(point_x, point_y, c = 'r', alpha=0.6)
    paint_y = 0
    for i in range(dim):
        paint_y += w[i]*(range_x**i)
    plt.plot(range_x, paint_y)
    plt.show()

```

Point_x: 圖上點的 x 座標

Point_y: 圖上點的 y 座標

Range_x: 畫線 x 的範圍且間距為多少 => ex: `np.arange(-3, 3, 0.01)`

w: 利用 x 求 y 的 weight => ex: $y = w[2]*x^2 + w[1]*x^1 + w[0]*x^0$

lim_x: x 軸顯示的範圍

lim_y: y 軸顯示的範圍

.....

畫單圖

```

12. integrationMap(point_x, point_y, range_x, w_1d, w_5d, w_10d, w_14d,
lim_x, lim_y)

def integrationMap(point_x, point_y, range_x, w_1d, w_5d, w_10d, w_14d, lim_x, lim_y):
    plt.title("Integration map")
    plt.xlim(lim_x)
    plt.ylim(lim_y)

    plt.scatter(point_x, point_y, c = 'r', alpha=0.6)
    paint_y = w_1d[1]*range_x + w_1d[0]
    plt.plot(range_x, paint_y)

    paint_y = 0
    for i in range(6):
        paint_y += w_5d[i]*(range_x**i)
    plt.plot(range_x, paint_y)

    paint_y = 0
    for i in range(11):
        paint_y += w_10d[i]*(range_x**i)
    plt.plot(range_x, paint_y)

    paint_y = 0
    for i in range(15):
        paint_y += w_14d[i]*(range_x**i)
    plt.plot(range_x, paint_y)
    plt.show()

```

Point_x: 圖上點的 x 座標

Point_y: 圖上點的 y 座標

Range_x: 畫線 x 的範圍且間距為多少 => ex: `np.arange(-3, 3, 0.01)`

W_1d: 利用 x 求 y 的 weight (1 維)

W_5d: 利用 x 求 y 的 weight (5 維)

W_10d: 利用 x 求 y 的 weight (10 維)

W_14d: 利用 x 求 y 的 weight (14 維)

lim_x: x 軸顯示的範圍

lim_y: y 軸顯示的範圍

.....
 畫整合圖 (1 維 5 維 10 維 14 維)

```
13. integrationMap_14d(point_x, point_y, range_x, Lambda1, Lambda2, Lambda3, Lambda4, lim_x, lim_y):
```

```
def integrationMap_14d(point_x, point_y, range_x, Lambda1, Lambda2, Lambda3, Lambda4, lim_x, lim_y):
    plt.title("Integration map")
    plt.xlim(lim_x)
    plt.ylim(lim_y)

    plt.scatter(point_x, point_y, c = 'r', alpha=0.6)

    paint_y = 0
    for i in range(15):
        paint_y += Lambda1[i]*(range_x**i)
    plt.plot(range_x, paint_y)

    paint_y = 0
    for i in range(15):
        paint_y += Lambda2[i]*(range_x**i)
    plt.plot(range_x, paint_y)

    paint_y = 0
    for i in range(15):
        paint_y += Lambda3[i]*(range_x**i)
    plt.plot(range_x, paint_y)

    paint_y = 0
    for i in range(15):
        paint_y += Lambda4[i]*(range_x**i)
    plt.plot(range_x, paint_y)

    plt.show()
```

Point_x: 圖上點的 x 座標

Point_y: 圖上點的 y 座標

Range_x: 畫線 x 的範圍且間距為多少 => ex: `np.arange(-3, 3, 0.01)`

Lambda1: 利用 x 求 y 的 weight (Lambda1)

Lambda2: 利用 x 求 y 的 weight (Lambda2)

Lambda3: 利用 x 求 y 的 weight (Lambda3)

Lambda4: 利用 x 求 y 的 weight (Lambda4)

lim_x: x 軸顯示的範圍

lim_y: y 軸顯示的範圍

.....

畫整合圖 (不同 Lambda 值的圖)

● 結果


(a)

```
degree 1:
training error
Ein = 1.3866913898163131

cross-validation errors [Leave one out]
Ein = 2.0427282054046034

cross-validation errors [five-fold]
Ein = 2.1304391233561053

testing error
Ein = 0.8628309039545659
```




(b)

```
degree 5:
training error
Ein = 0.48002978426523507

cross-validation errors [Leave one out]
Ein = 2.7092139683151566

cross-validation errors [five-fold]
Ein = 5.0003041636632055

testing error
Ein = 12.040824692018976
```




```
degree 10:
training error
Ein = 0.30905398694509595

cross-validation errors [Leave one out]
Ein = 311.3479093240394

cross-validation errors [five-fold]
Ein = 8956.427181918847

testing error
Ein = 4.581530278919752
```




```
degree 14:
training error
Ein = 3.18467583965206e-10

cross-validation errors [Leave one out]
Ein = 238719.7191503484

cross-validation errors [five-fold]
Ein = 393416.5905571226

testing error
Ein = 535270.7766524113
```

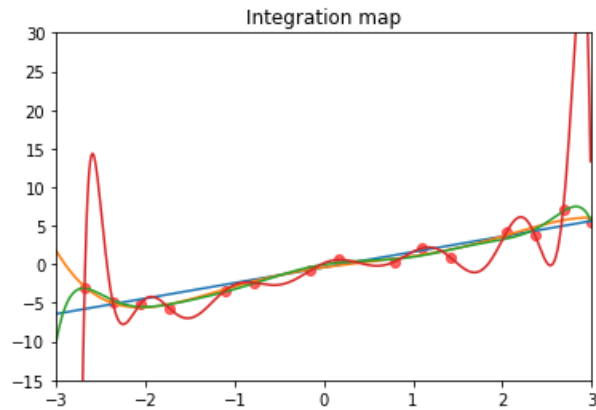


(a)(b) 整合後的圖與各個 E_{in} :

整合

$$y = 2x + \varepsilon:$$

	Training Error	Leave-One-Out	Five-Fold	Testing Error
degree				
1	1.386691e+00	2.042728	2.130439	0.862831
5	4.800298e-01	2.709214	5.000304	12.040825
10	3.090540e-01	311.347909	8956.427182	4.581530
14	3.184676e-10	238719.719150	393416.590557	535270.776652



(c)

Degree = 1:

training error

$E_{in} = 0.2855842330957012$

cross-validation errors [Leave one out]

$E_{in} = 0.4347907164855316$

cross-validation errors [five-fold]

$E_{in} = 0.4261943489427151$

testing error

$E_{in} = 0.2148116633169592$

Degree = 5:

training error

$E_{in} = 0.022749578412012257$

cross-validation errors [Leave one out]



$E_{in} = 0.45245518035841253$

cross-validation errors [five-fold]

$E_{in} = 0.31318001820231345$



testing error

$E_{in} = 0.017149595757925486$



Degree = 10:
 training error
 $E_{in} = 0.008543802283289638$
 cross-validation errors [Leave one out]
 $E_{in} = 19655.07221982198$
 cross-validation errors [five-fold]
 $E_{in} = 7727.102656358748$
 testing error
 $E_{in} = 3.27638855143219$

Degree = 14:
 training error
 $E_{in} = 0.008722371661576267$
 cross-validation errors [Leave one out]
 $E_{in} = 61334525.39174279$
 cross-validation errors [five-fold]
 $E_{in} = 35554240.49534663$
 testing error
 $E_{in} = 47.84411899986448$




整合的圖與 E_{in} :

整合

$$y = \sin(2\pi x) + \varepsilon:$$

degree	Training Error	Leave-One-Out	Five-Fold	Testing Error
1	0.285584	4.347907e-01	4.261943e-01	0.214811
5	0.022750	4.524552e-01	3.131800e-01	0.017150
10	0.008544	1.965507e+04	7.727103e+03	3.276389
14	0.008722	6.133453e+07	3.555424e+07	47.844119



(d)

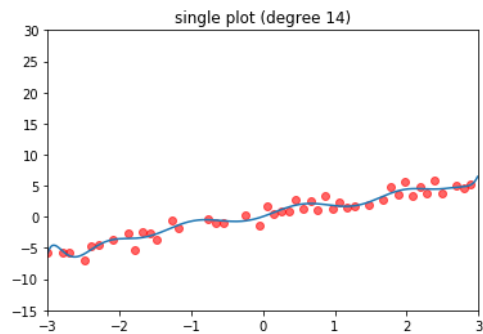
$y = 2x + \varepsilon$
degree = 14
m = 60:

training error
Ein = 0.6342411012999404

cross-validation errors [Leave one out]
Ein = 8.08143303088541

cross-validation errors [five-fold]
Ein = 4.2317957672072

testing error
Ein = 1.612615717384139




$y = 2x + \varepsilon$
degree = 14
m = 160:

training error
Ein = 0.9266215419636364

cross-validation errors [Leave one out]
Ein = 1.3493753366559922

cross-validation errors [five-fold]
Ein = 1.4506811309874483

testing error
Ein = 1.235031839377005




$y = 2x + \varepsilon$
degree = 14
m = 320:

training error
Ein = 1.1164959090931166

cross-validation errors [Leave one out]
Ein = 1.3023577450137498

cross-validation errors [five-fold]
Ein = 1.3059351941119934

testing error
Ein = 1.086129304456182



整理的 Five-Fold 和 Testing Error 的 E_{in} :

整合

$y = 2x + \varepsilon$ (m = 60, m = 160, m = 320):

	Five-Fold	Testing Error
m		
60	4.231796	1.612616
160	1.450681	1.235032
320	1.305935	1.086129

(e)


Lambda = 0

```
training error
Ein = 0.25121674041482744

cross-validation errors [leave one out]
Ein = 6221.2383428876465

cross-validation errors [five-fold]
Ein = 72753.8502270516

testing error
Ein = 0.2512167404533986
```




Lambda = 0.001/m

```
training error
Ein = 0.41235638924177087

cross-validation errors [leave one out]
Ein = 1.4726688386786786

cross-validation errors [five-fold]
Ein = 1.666109924203121

testing error
Ein = 0.41235638924177087
```




Lambda = 1/m

```
training error
Ein = 0.5485837159232257

cross-validation errors [leave one out]
Ein = 0.7718614404478981

cross-validation errors [five-fold]
Ein = 0.704050140377093

testing error
Ein = 0.5485837159232259
```




Lambda = 1000/m

```
training error
Ein = 2.9698190806429117

cross-validation errors [leave one out]
Ein = 2.84803883319791

cross-validation errors [five-fold]
Ein = 2.4696189089302867

testing error
Ein = 2.9698190806429117
```




整理各個用 Lambda 做 regularization 的 E_{in} :

整合

$y = 2x + \varepsilon$ (regularization), $m = 20$:

Lambda (λ)	Training Error	Leave-One-Out	Five-Fold	Testing Error
0	0.251217	6221.238343	72753.850227	0.251217
0.001/m	0.412356	1.472669	1.666111	0.412356
1/m	0.548584	0.771861	0.704050	0.548584
1000/m	2.969819	2.848039	2.469619	2.969819



● 討 論

從這幾題中可以觀察出

1. 當維度越大時，在做 **testing error** 越容易產生極大的誤差，原因是在於當在高維度且要符合每個 **training** 的 x, y 值時，很有可會使模型產生極大的弧度，而造成 **overfitting**。
2. 我們可以利用 **cross-validation errors** 評估出是否會發生 **overfitting**，從上面幾個圖形可以觀察出當我們的圖越曲折時，**cross-validation errors** 的值基本上都是偏大。
3. 當資料的樣本數越多時，模型預測會越準確。
(在題型(d)的 **testing error** 可以看出，在 $m=320$ 的 **testing error** 是最小的)
4. **Regularization** 和 **regression** 可以看出是有差別的，在題型(e) $\lambda=0$ 時基本上就是 **regression**。在 $\lambda=0$ 時的圖也是最為複雜的，而做了 **regularization** 的圖則是較為平緩。所以可以看出 **regularization** 可以一定程度的避免 **overfitting** 的發生，但如果 **regularization** 力度太大則會造成整個模型的誤差極大。
5. 在題型(e) 比較不同 λ 值所產出的模型可以發現，當 λ 值越大時圖是越平緩的，所以說當 λ 值越大時 **regularization** 的力度越大，圖會變得越平緩但誤差也會跟著變大。